

1. ¿Se puede considerar la búsqueda de arquitectura neuronal (NAS) como un subcampo de AutoML?

1 / 1 punto

☐ No

☒ Sí

✓ **Correcto**

¡Exactamente! NAS puede verse como un subcampo de AutoML y tiene una superposición significativa con la optimización de hiperparámetros y el metaaprendizaje.

2. ¿Cuáles de las siguientes son dimensiones de la técnica Neural Architecture Search (NAS)? (Seleccione todas las que correspondan)

1 / 1 punto

☒ Estrategia de Estimación de Desempeño

✓ **Correcto**

¡Lo entendiste! El objetivo de NAS suele ser encontrar una arquitectura con el rendimiento predictivo más alto.

☐ Formación y Validación de la Arquitectura

☒ Estrategia de búsqueda

✓ **Correcto**

¡Seguid así! La estrategia de búsqueda detalla cómo explorar el espacio de búsqueda.

☒ Espacio de búsqueda

✓ **Correcto**

¡Derecha! El espacio de búsqueda define el rango de arquitecturas que se pueden representar.

3. ¿Qué permite el espacio de búsqueda en Neural Architecture Search (NAS)? (Seleccione todas las que correspondan)

1 / 1 punto

☒ Restringir los espacios de búsqueda ilimitados para tener una profundidad máxima.

✓ **Correcto**

¡Gran trabajo! Da lugar a espacios de búsqueda con (potencialmente muchas) dimensiones condicionales.

☐ Definir cómo exploramos el espacio de búsqueda.

☒ Reducir el tamaño del espacio de búsqueda incorporando conocimientos previos sobre propiedades adecuadas.

**Correcto**

¡Así es! Esta tarea puede simplificar el espacio de búsqueda.



Definiendo qué arquitecturas neuronales podríamos descubrir en principio.

**Correcto**

¡Estás en el buen camino!. El espacio de búsqueda define qué arquitecturas se pueden representar.

4. En la arquitectura de red neuronal estructurada en cadena (NNA), el espacio está parametrizado por (Seleccione todo lo que corresponda):

1 / 1 punto

Un número de n capas completamente conectadas secuencialmente.

**Correcto**

¡Correcto! Un NNA estructurado en cadena se puede escribir como una secuencia de n capas.



Las ramas múltiples con tipos de capas adicionales y conexiones de salto.



Hiperparámetros asociados a la operación.

**Correcto**

¡Bien hecho! El espacio de búsqueda está relacionado con el número de unidades para redes totalmente conectadas.



La operación que cada capa puede ejecutar.

**Correcto**

¡Excelente!. Entre las operaciones más comunes se encuentran la agrupación, la convolución y las capas más avanzadas.

5. ¿Cuáles son las características principales del **aprendizaje automático automatizado** (AutoML)? (Seleccione todas las que correspondan)

1 / 1 punto

AutoML es el proceso de automatización de la ingeniería de arquitectura y búsqueda del diseño de modelos de aprendizaje automático.



AutoML tiene como objetivo automatizar la toma de decisiones de una manera objetiva y basada en datos.

**Correcto**

¡Correcto! AutoML determina el enfoque que funciona mejor para una determinada aplicación.



Las tecnologías AutoML democratizan la IA con aprendizaje automático personalizado de última generación.

**Correcto**

¡Eso es cierto! AutoML busca hacer que los enfoques de aprendizaje automático de última generación sean accesibles para los científicos de datos con experiencia limitada en aprendizaje automático.



AutoML tiene como objetivo automatizar el proceso de aprendizaje automático de extremo a extremo para producir soluciones más simples y rápidas.

**Correcto**

¡Por cierto! AutoML permite a los desarrolladores, incluso aquellos con una experiencia mínima en aprendizaje automático, producir fácilmente soluciones simples y óptimas.

6. ¿Cuáles son los dos tipos principales de espacios de búsqueda?

1 / 1 punto



Complejo y Simple



Grande y pequeño



Largo y corto



macro y micro

**Correcto**

¡Buen trabajo! Aunque sus nombres son un poco al revés, así es como se llaman.

7. Al medir la eficacia de AutoML, se han propuesto varias estrategias para reducir la estimación de costos de rendimiento, que incluyen (seleccione todas las que correspondan):

1 / 1 punto



Herencia de Peso/ Morfismos de Red

**Correcto**

¡Lo superó! Mediante el uso de morfismo de red, los pesos de las arquitecturas novedosas se inicializan en función de los pesos de las arquitecturas previamente entrenadas.



Estimaciones de fidelidad más bajas

**Correcto**

¡Sí! Las estimaciones de menor fidelidad intentan reducir el tiempo de entrenamiento reformulando el problema.



Extrapolación de la curva de aprendizaje

**Correcto**

¡Bien hecho! La extrapolación es una opción sensible y válida basada en la suposición de que la curva de aprendizaje se puede predecir de manera confiable.



Aprendizaje reforzado

8. Las **estimaciones de fidelidad más baja** son una estrategia de estimación de rendimiento que permite (seleccione todas las que correspondan):

1 / 1 punto

☒ Entrenamiento con menos filtros por capa

☒ **Correcto**

¡Camino a seguir! La estrategia de estimaciones de fidelidad más baja utiliza menos filtros por capa y menos celdas.

☒ Entrenamiento en un subconjunto de los datos

☒ **Correcto**

¡Correcto! También reduce los tiempos de entrenamiento.

☐ Entrenamiento para algunas épocas.

☒ Entrenamiento en baja resolución

☒ **Correcto**

¡Eso es todo! Como resultado, la menor fidelidad reduce el costo computacional.

9. ¿Puede **el morfismo de la red** modificar una arquitectura sin modificar la función de la red?

1 / 1 punto

☐ No

☒ Sí

☒ **Correcto**

¡Exactamente! Esta propiedad aumenta la capacidad de la red conservando como resultado un alto rendimiento.